


## Када можемо користити шест знакова?

- посматрајмо 2 независна узорка  $(X_1, X_2, \dots, X_n)$  и  $(Y_1, \dots, Y_n)$  ш.г. су  $(X_1, Y_1), \dots, (X_n, Y_n)$  независне.
- овакву поставку смо видели код стандард т теста где смо уз претпоставку да  $D_i = X_i - Y_i \sim N(\mu, \sigma^2)$  ишћивали да ли постоји статистички значајна разлика између обележја  $X$  и  $Y$ , шестирајући шћивање о вредности параметра  $\mu$ .
- Шта ако не знамо да ли  $D_i \sim N(\mu, \sigma^2)$ ?
  - извршћемо шестирање о медијани о  $D_i$
- нека је  $m_e$  медијана о  $D_i$  ( $D_1, \dots, D_n$  је и дане  $n$ с)
- шта нам говори  $m_e > 0$ ?



$$P\{X_i - Y_i > 0\} > \frac{1}{2}$$

$$\Leftrightarrow P\{X_i > Y_i\} > \frac{1}{2}$$

вероватноћа да  $D_i$  узме вредности вету о  $m_e$  је 0,5

$\Rightarrow$  вероватноћа да  $D_i$  узме вредности вету о 0 је вету о 0,5

- дакле, вредности  $m_e$  вету о 0 упућују на то да обележје  $X$  узима значајно вету вредности о обележја  $Y$

48.

A - гужина дејства 1. лекс

B - гужина дејства 2. лекс

$D = B - A$  - разлика гужине дејства о 2 лекс

$m_e$  - медијана о  $D$

- не постоји статистички значајна разлика у дужини дејства  
обух лекова  $\Rightarrow m_e = 0$   $\frac{1}{2} = P\{D > 0\} = P\{B > A\}$

- постоји статистички значајна разлика  $\Rightarrow m_e \neq 0$

$$H_0: m_e = 0 \quad \text{vs} \quad H_1: m_e \neq 0$$

$$T = \sum_{i=1}^n I\{D_i > 0\} - \text{вешт стат.}$$

$n = 12 > 10 \rightarrow$  користи се стандардизовану вешт статистику:


$$T^* = \frac{T - \frac{n}{2}}{\sqrt{\frac{n}{4}}} \sim N(0, 1)$$

$\downarrow$   
укупно

$$W = \{|T^*| \geq c\} - \text{критична област}$$

Изражимо  $c$ :

$$c \text{ је в.г. } P\{T^* \in W \mid H_0 \text{ вистина}\} = 0,05$$



$$\Rightarrow \Phi(c) = 1 - \frac{0,05}{2} \Rightarrow c = \Phi^{-1}(0,975) \\ \Rightarrow c = 1,96$$

- реализована вредност од  $T^*$  је  $\frac{9 - \frac{12}{2}}{\sqrt{\frac{12}{4}}} = \sqrt{3} = 1,732051$

$\Rightarrow T^*$  није ушло у критичну област, па се не одбацује  $H_0$ . Дакле, не можемо рећи да постоји статистички значајна разлика у дужини дејства обух лекова.

- Како би тласили  $H_1$  ако желимо да испитамо да ли 2. лек има значајно друге дејство од 1. лека?

$$H_1: m_e > 0$$

## Вилкоxonов тест (означених радова)

(Wilcoxon signed rank test)

- тестирамо хипотезе о вредности медијане симетричног и апсолутно континуалног расподеле однезја  $X$



$$H_0: m_e = m_0 \quad \text{vs} \quad H_1: m_e \neq m_0$$

- Како је Вилкоxonову тест. стат. мало лакше заштитити, покушајмо са слике да схватимо интуицију:

- ако је  $H_0$  тачна, очекујемо да тачке из узорка буду равномерно разлажене око  $m_0$

↓  
јер је расподела однезја симетрична

Густина однезје при  $H_0$



- природно ушито број тачака, или у девио од  $m_0$

- када бисмо сортирали тачке по апсолутној вредности њихових растојања од  $m_0$ , то би обрнуто изгледало овако:


$$W = 2 + 4 + 6 + 8 = 20$$

1 2 3 4 5 6 7 8  
(. . . . . . . .),

Тге у плате платке ове које у бете од  $m_0$ , а црвене мање од  $m_0$

- Ако је  $m_e > m_0$ , каква слика уге у укупно плате

$$W = 2 + 3 + 5 + 6 + 7 = 23$$



1 2 3 4 5 6 7  
(. . . . . . . .)

више платних платка уру десно кроју нула

Закле, у укупно  $m_e > m_0$  угу бету регну држебу платних платка у обико сортираном нузу

- Сада можемо боље разумети шест платних коју је Вилкоксов препознато:

$$W = \sum_{i=1}^n R_i I\{X_i > m_0\} - \text{Вилкоксове шест платних}$$

$R_i$  - "ранг" елемента  $|X_i - m_0|$ , уј. кето регну држ у расуте сортираном нузу  $|X_1 - m_0|, \dots, |X_n - m_0|$

$$\textcircled{1} \text{ при } H_0 : E W = \frac{n(n+1)}{4}, \quad D W = \frac{n(n+1)(2n+1)}{24}$$

За  $n > 12$ :

$$T = \frac{W - E W}{\sqrt{D W}} \underset{\text{при } H_0}{\sim} N(0, 1)$$

Као што смо видели, у укупно  $H_1: m_e > m_0$  угу бету вред-ности  $W$ , та је шест критична вредност:  $\{W \geq c\}$

Ако је  $\Pi_1: m \in m_0 \rightarrow \text{кр. односи: } \{W \in C\}$ .

За  $n \geq 2$  користитемо стандардизовану теорију  
својих  $T$  и тада кривичке односи изгледају овако:

$$\Pi_1: m \in m_0 \rightarrow \{T \geq c\}$$

$$\Pi_1: m \in m_0 \rightarrow \{T \leq c\}$$

$$\Pi_1: m \neq m_0 \rightarrow \{|T| \geq c\}$$

**49.** Како нас занима да ли се променио просек процената неписмених, према томе извршило тестирање о очекивању расподела. Пошто је расподела симетрична, очекивање и медијана су исти.

Узравнудимо својих својих  $W$ .

1. корак: рачунамо  $X_1 - 0,7, X_2 - 0,7, \dots, X_n - 0,7$

-0.10 -0.20 -0.08 1.00 0.05 0.30 -0.01 0.10 0.10 -0.13 0.20 0.80 0.25 -0.17 0.40 0.50 1.30 -0.05 0.09 -0.09

2. корак: рачунамо  $|X_1 - 0,7|, |X_2 - 0,7|, \dots, |X_n - 0,7|$  и ставимо знак

0.10 0.20 0.08 1.00 0.05 0.30 0.01 0.10 0.10 0.13 0.20 0.80 0.25 0.17 0.40 0.50 1.30 0.05 0.09 0.09

- - - + + + - + + - + + + - + + + - + -

3. корак: сортирамо  $|X_1 - 0,7|, \dots, |X_n - 0,7|$  и рангирамо их

0.01 0.05 0.05 0.08 0.09 0.09 0.10 0.10 0.10 0.13 0.17 0.20 0.20 0.25 0.30 0.40 0.50 0.80 1.00 1.3

1 2,5 2,5 4 5,5 5,5 8 8 8 10 11 12,5 12,5 14 15 16 17 18 19 20

+ + + + + + + + + + + + + + + + +

4. корак: сабирамо рангове изнад "+", односно сабирамо рангове од  $|X_i - 0,7|$  ако је  $X_i - 0,7 > 0$

$$W = 2,5 + 5,5 + 8 + 8 + 12,5 + 14 + 15 + 16 + 17 + 18 + 19 + 20 = 155,5$$

Како се врши рангирање?

- најпре се извод свих елемената сортирајући их по  $|X_i - 0,7|$  упишу редом бројеви од 1 до  $n$ . Ако у сортираном низу  $|X_i - 0,7|$  нема понављања, тогласмо

- ако има понављања, он елементи 'дело' ранг, тј. који ранг је аритметичка средина премадног уписањих бројева

- тако 0,05 и 0,05 имају рангове 2 и 3, вет  $\frac{2+3}{2}$  и сл.

## Вилкоксон тест за 2 независна узорка (Wilcoxon rank-sum test)

- Сада ћемо испитивати да ли постоји статистички значајна разлика између вредности 2 независне однежја  $X$  и  $Y$

- Нека су дава 2 независна узорка  $X = (X_1, \dots, X_n)$  и  $Y = (Y_1, \dots, Y_m)$  из истих расподела као  $X$  и  $Y$ , редом

- Требаће нам да су расподеле  $X$  и  $Y$  адекватно неоднежене и да важи:  $X \stackrel{d}{=} Y + c$


ознака  $X \stackrel{d}{=} Y + c$  значи да  $X$  и  $Y + c$  имају исту расподелу, али не нужно да су  $X$  и  $Y + c$  једнаке као функције!

Дакле,  $X \stackrel{d}{=} Y + c \Rightarrow F_X(x) = F_{Y+c}(x) = P\{Y+c \leq x\} = F_Y(x-c)$

Одакле следи:  $f_X(x) = f_Y(x-c)$

Када ћемо рећи да  $X$  узима значајно веће вредности од  $Y$ ? Посматрајмо с.

Нека је  $\mu$  средња вредност. Како изгледају густине однежја  $X$  и  $Y$ ?



Са слике видимо да се вредности однежја  $X$  и  $Y$  састоје од истих вредности, али су померене.  $A - c = \{a - c, a \in A\}$ .

- Ветина елементарна статистика  $A$  је ветина од елементарна статистика  $A-c$ , па очекујемо да, ако је  $c$  значајно позитивно, узорак  $(X_1, \dots, X_n)$  садржи више светле вредности него узорак  $(Y_1, \dots, Y_m)$

- Односно, ако **плавим** шаткама означимо вредности  $(X_1, \dots, X_n)$  а **црвеним** вредности  $(Y_1, Y_2, \dots, Y_m)$ , очекујемо следећу ситуацију:



Дакле, очекивање да  $\mu$  је  $X$  значајно веће од  $Y$  се своди на очекивање да  $\mu$  је  $c > 0$

Вилкоксонским тестом ћемо дакле тестирају:

$$H_0: c = 0 \quad \text{vs} \quad H_1: c \neq 0$$

$\Updownarrow$   
 не постоји  
 значајна разлика  
 између одређења  $X$  и  $Y$

Предложена статистика је  $T = \sum_{i=1}^n R_i$ , где је

$R_i$ : "ранг" елементарна  $X_i$  у обједињеном узорку  $(X, Y)$ .

Односно,  $R_i$  је редни број  $X_i$  у растуће сортираном низу  $X_1, X_2, \dots, X_n, Y_1, \dots, Y_m$ .

Видели смо да у случају  $H_1: c > 0$  има веће вредности  $R_i$  (плаве шатке су у плавој групи од црвених),

та у том случају критична област изгледа:  $W = \{T \geq 2\}$   
 - ако је  $H_1: c < 0 \Rightarrow W = \{T \leq 2\}$

Ⓙ Ако је  $H_0$  тачна,  $ET = \frac{n(n+m+1)}{2}$ ,  $DT = \frac{nm(n+m+1)}{12}$

и тада за  $n, m > 10$   $T^* = \frac{T - ET}{\sqrt{DT}} \sim N(0, 1)$

Јакне, за велике  $m, n$  користимо тај сити  $T^*$  у следеће критичке области:

$H_1: c > 0 \rightarrow W = \{T^* \geq 2\}$

$H_1: c < 0 \rightarrow W = \{T^* \leq -2\}$

$H_1: c \neq 0 \rightarrow W = \{|T^*| \geq 2\}$

50. Нека  $X$  представља копичу података у ретину А, а  $Y$  копичу података у ретину В. Према теорему 49,  $m$  је  $EX = EY$ . Како је представљена ова теорема:  $X \stackrel{d}{=} Y + c$ , зато је  $EX = EY + c$ , па је  $EX = EY \Rightarrow c = 0$

Зашто хипотезе изгледају овако:

$H_0: EX = EY$  vs  $H_1: EX \neq EY$   
 или  $c = 0$  или  $c \neq 0$

Задусмо узратунали  $T = \sum_{i=1}^n R_i$ , потврдио је да сортирано одје-  
 гичени узорак података у оди ретина

1.3 2.5 2.6 2.7 2.8 2.9 3.0 3.3 3.4 3.4 3.5 4.0 4.1 4.8 4.9 4.9 5.0 5.1 5.2 6.0 7.0 10.3

зашто је потврдио да  $T$  је ратирано, што се чини исто као  
 у претходном задатку:

1.3 2.5 2.6 2.7 2.8 2.9 3.0 3.3 3.4 3.4 3.5 4.0 4.1 4.8 4.9 4.9 5.0 5.1 5.2 6.0 7.0 10.3  
 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22  
 A A A A A A A A A A A A A A A



Спозете што нам преостале јесу да саберемо ранке износ 'A', тј. да саберемо ратне бројеве елементарних низа постављених у региону A у сортираном одређеном узорку

$$T = 1 + 2 + 3 + 4 + 5 + 7 + 9,5 + 13 + 14 + 15,5 + 17 = 91$$